



UNIVERSIDADE FEDERAL  
DE ALAGOAS



# Towards Real-World Blind Face Restoration with Generative Facial Prior



Processamento Digital de Imagens

Leonardo Alexandre



# Motivação



A restauração cega de imagens é restaurar uma imagem degradada sem usar informação da imagem real ou da função de degradação, No entanto, entradas de qualidade muito baixa podem dificultar esse processo.

Input image



GFPGAN output



# Objetivo




Neste trabalho, propomos GFP-GAN que aproveita antecedentes ricos e diversos encapsulados em um GAN de face pré-treinado para restauração cega de faces. Este Generative Facial Prior (GFP) é incorporado ao processo de restauração facial por meio de camadas de transformação de recursos espaciais, o que permite que este método alcance um bom equilíbrio entre realidade e fidelidade.

# Outras Soluções



O GFP-GAN foi comparado com vários métodos de restauração de rosto de última geração como HiFaceGAN , DFDNet e PSFRGAN.



Entrada

DeblurGANv2 \* Wan *et al.*

HiFaceGAN

DFDNet

PSFRGAN

PULSO


**GFP-GAN**

GT

# Outras Soluções



Também foi comparado com métodos de restauração de imagem: RCAN , ESRGAN e DeblurGANv2



Bicubic

RCAN\*

ESRGAN\*

GFP-GAN

GT

# Metodologia



O GFP-GAN é composto por um módulo de remoção de degradação (UNet) e um GAN de face pré-treinado (Style-GAN2 ), Eles são interligados por um mapeamento de código latente e várias camadas Channel-Split Spatial Feature Transform (CS-SFT)

# Metodologia



Especificamente, o módulo de remoção de degradação é projetado para remover degradação complicada e extrair dois tipos de recursos:

1. Características latentes
2. Recursos espaciais de multi-resolução

As características latentes são usadas para mapear a imagem de entrada para o código latente mais próximo no StyleGAN2 os características espaciais são usados para modular os recursos do StyleGAN2.

# Objetivo do Modelo



O objetivo de aprendizagem de treinar o GFP-GAN consiste em:


1. Perda de reconstrução que restringe os resultados  $\hat{y}$  perto da verdade fundamental  $y$ .
2. Perda adversária para restaurar texturas realistas
3. Perda de componente facial proposta para melhorar ainda mais os detalhes faciais.
4. Perda de preservação de identidade.





# Testes particulares



# Testes particulares



# Testes Particulares



# Referências



1. <https://arxiv.org/pdf/2101.04061v2.pdf>
2. <https://arxiv.org/pdf/2107.10833v2.pdf>
3. <https://arxiv.org/abs/1809.00219>